도서 데이터 수집 현황

레이어 구조 · 단계별 수집 계획 · 필드 결측 현황

2026-08-28
SSAFY 15기 · 대전 1반 102팀
설계 미팅 자료

3,528,013	1,082,390	301,154	28,968	174,388
L0 통합 카탈로그	L1 추천 후보	1단계 대상	정보나루 (주 보강원)	국중 회수 텍스트
국중 ∪ 정보나루	대출 72+ ∪ 신간	노출 90% 밴드	1단계의 9.6%	목차 79,720 포함

01 데이터 레이어

L0	3,528,013 종	**통합 카탈로그 — 조회·검색 표면.** 국립중앙도서관 2,019,407 ∪ 정보나루 2,791,309. 어떤 책을 검색해도 나와야 하므로 최대한 넓게 유지한다. **수집 대상 아님.**
L1	1,082,390 종	**추천 후보 — 텍스트 보강 대상.** 누적 대출 72회 이상(전국 대출량의 99.0% 커버) ∪ 2025년 이후 신간. **종수의 66%를 버리고 대출량은 1.0%만 잃는 지점.** 여기가 지금 수집 중인 층이다.
L2	미착수	**벡터 인덱스.** L1 중 텍스트 확보분을 임베딩해 HNSW 인덱스로 만든다. L1 수집이 일정 수준에 도달한 뒤 착수.

왜 나누는가

조회와 추천은 요구가 반대다. **조회는 넓어야** 하고(없으면 신뢰가 깨진다), **추천은 좁아야** 한다(아무도 안 빌린 책을 들이밀면 품질이 떨어진다). 비용도 다르다 — L0 전량 보강은 정보나루 3만/일 기준 **117일**, L1은 **32일**이다. L0에만 있는 책은 사용자가 실제로 조회할 때 온디맨드로 채운다.

02 L1 단계별 수집 계획

전량을 다 긁기 전에 멈출 수 있다는 전제로 순서를 짰다. **멈춘 시점까지가 가장 값어치 있어야 한다.**

1단계 · 노출 90%	2단계 · 신간	3단계 · 꼬리
301,154	120,877	532,745
누적 대출이 전체의 90%에 닿을 때까지. 대출 903~642,320회 구간. 여기만 끝내도 **이용자가 실제로 마주치는 책의 90%**를 덮는다.	2025년 이후 발행. 대출 이력이 없어 1단계에 못 들지만 추천 품질에 직결되므로 꼬리보다 앞세운다. **협업필터링이 19%뿐이라 임베딩이 필수인 구간.**	L1 중 나머지. 권수는 56%지만 **대출량은 9.8%**. 온디맨드로 돌리는 편이 합리적 — 사용자가 실제로 조회할 때 채운다.
28,968 / 301,154 · 9.6% · 잔여 9일 진행 중	0 / 120,877 · 0% · 추가 4일 대기	0 / 532,745 · 0% · 전량 시 +18일 보류

대출 집중도 — 1단계 경계의 근거

상위 N권	누적 대출 비중
10,000	24.5%
50,000	52.2%
100,000	67.4%
200,000	82.6%
301,154 (1단계)	**90.0%**
600,000	96.4%
954,776 (전량)	100.0%

일정 제약 — 일일 3만 호출

정보나루·카카오 모두 하루 약 3만 호출이 상한이다(실측). **1단계 완주 9일, 전량 32일.**

권고: 1단계에서 끊고 꼬리는 온디맨드. 나머지 23일이 커버하는 것은 대출량의 10%뿐이다.

주의 — 인기 편향

데이터가 잘 갖춰진 책이 추천에 잘 뜨고, 그것이 다시 대출을 늘린다. **명시적 novelty 페널티가 없으면 "추천"이 아니라 "인기순"이 된다.**

수집 필드와 결측 현황

소스별 확보 항목 · 실측 채움율 · 읽을 때의 주의

03 텍스트 보강 소스 — 우선순위 순

층화 파일럿 582건으로 순서를 확정했다. **정보나루가 카카오 위에 +23.1%p를 더하는데, 카카오는 정보나루 위에 +2.7%p뿐이다.** 카카오가 이기는 층은 2015년 이후 신간 하나이고 격차도 2.5%p다.

순위	소스 · 역할	수집 방법	수집량	유효율	제공 항목
①	**국립중앙도서관** URL 텍스트 회수 · 완료	파일 직접 수신 **API 쿼터 0회**	174,388	—	**목차 79,720(중앙 700자) · 소개 74,694(974자) · 요약 19,974(1,108자)** **목차의 유일한 출처** — 정보나루 12개 API·카카오 어디에도 없다
②	**정보나루** 주 보강원 usageAnalysisList	API · ISBN당 1호출 일 3만 상한	28,968	**99.1%**	서지 · 소개문 · KDC · 부가기호 · 표지 · 키워드 50개 **함께대출 10건 · 마니아/다독자 추천 · 월별 대출이력 12개월 · 연령×성별**
③	**카카오** 잔여분 전용 도서 검색	API · ISBN당 1호출 일 3만 상한 (별도 쿼터)	29,600	94.8%	서지 · **소개문 250자(줄거리 중심)** · 표지 · 판매상태 · 정가 커버리지 순증은 +2.7%p 뿐이나 **내용이 겹치지 않아 이어붙이면 이득**
—	**정보나루 보유 원장** 벌크 CSV · 수집 완료	파일 다운로드 · 1,660개관	**1.21**억 행	전수	관 × ISBN × 대출 × 권수 — 필터·랭킹·수집 우선순위의 근거

두 소스는 경쟁이 아니라 보완

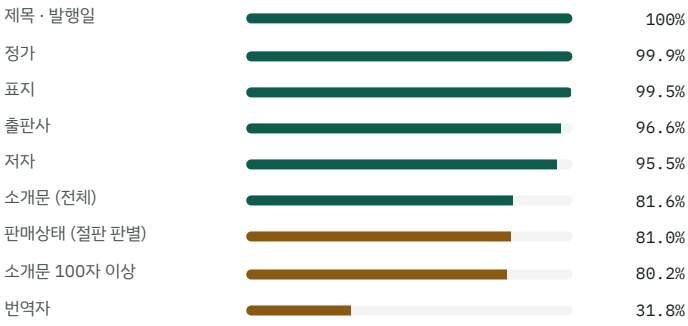
같은 책 375쌍을 비교하니 **6-gram 포함률 중앙 0.06 — 65.9%가 거의 다른 문장**이었다. 카카오는 **줄거리**, 정보나루는 **작품의 위치·의의**를 준다. 길이는 카카오 251자 / 정보나루 145자지만 카카오는 250자 하드캡에서 **84.5%가 문장 중간에 잘린다**. **표시용은 정보나루, 임베딩 입력은 이어붙임**이 맞다.

04 필드별 결측 현황

② **정보나루** — 주 보강원 (유효 28,714건)



③ **카카오** — 잔여분 전용 (매칭 28,048건)



읽을 때 반드시 감안할 것 — 표본이 최상위 구간이다

위 수치는 **수집 하루치**로 낸 것이고, 표본은 우선순위 큐의 **최상위 구간**이다 (1단계의 9.6%, L1 전체의 2.7%). 수요 상위일수록 소개문·키워드·이용 데이터가 잘 갖춰져 있으므로 **모든 채움율은 상한이며 앞으로 아래로만 움직인다.** 파일럿에서 꼬리 구간의 소개문 확보율은 52.5%였다. **확정 판단은 1단계 완주(약 9일) 후.**

연령×성별 13.5% — 원인 규명 완료

누적 대출이 아니라 **최근 12개월 대출량**에 연동된다. 최근 3천 회 이상 75.2% / 1천~3천 17.1% / 1천 미만 0%. **인구통계 개인화는 "지금 인기 있는 책"에서만 작동한다.** 전 카탈로그 축이 아니라 트렌딩 구간 전용 보조 신호로 설계할 것.

키워드는 소개문에 종속된다

소개문 없는 1,887건 중 **73%는 키워드도 없다.** 정보나루가 소개문에서 키워드를 추출하는 것으로 보인다. **두 결측은 독립이 아니다** — 텍스트 없는 책은 키워드로도 메울 수 없다. 목차·요약은 정보나루 12개 API 어디에도 없어 국중 회수분이 유일한 출처다.

05 다음 단계와 결정 사항

안건	현황	권고
수집 범위	1단계 9.6% · 잔여 9일 전량은 32일	**1단계 완주 후 중단 — 노출 90%를 덮고 꼬리는 온디맨드**
카카오 병행 시점	쿼터가 별개라 동시 진행 가능 커버리지 순증은 +2.7%p	**병행 — 순증은 작지만 내용이 겹치지 않아 이어붙이면 이득**
목차 활용	국중 회수 79,720건 확보 중앙 700자 (소개문의 5배)	**임베딩 입력에 포함 — 현재 미반영 상태**
인구통계 활용	13.5%, 최근 인기작 한정	트렌딩 구간 전용 보조 신호로 한정
L2 착수 시점	미착수	1단계 완주 후 — 지금 만들면 곧 재생성해야 한다

재현: database/_pipeline/scripts/ — enrich_from_data4library.py · enrich_from_kakao.py · build_enrich_queue.py